

PORTFOLIO

은하영

Phone

010-6204-5201

Email

ematics0321@naver.com

INTRODUCTION

안녕하세요, 지원자 은하영입니다.



★ 나를 소개하는 키워드

#꾸준함

#긍정

#끈기

#주도적

#ENTJ

#전달력



학력사항

2021.02~ 2026.02

수원대학교 데이터과학부 21학번



보유스킬

- Language: **Python**
- Database&Warehouse: **PostgreSQL, AWS Redshift, AWS S3, Google Bigquery**
- Cloud&Infrastructure: **AWS EC2, Docker**
- Language: **Apache Airflow, dbt(Data Build Tool)**
- Collaboration: **Slack, Notion, Github**

★ 수상이력/활동내용

- 프로그래머스 데이터 엔지니어링 6기 (2025.04~2025.07)
- 한이음 ICT 멘토링 학술대회 (우수상)





자격사항

- SQL 개발자(SQLD)

PROJECTS

1) E-COMMERCE 상품추천 및 데이터 플랫폼 구축
(프로그래머스 데이터 엔지니어링 2025.07)

2) MIMIC-IV 대용량 의료 데이터 분석
(수원대학교 학부연구생, 2024.03 ~ 2024.10)



PROJECTS

1) e-commerce 상품추천 및 데이터 플랫폼 구축

영상링크: <https://www.youtube.com/watch?v=WwBf5CpmvFo>



기간: 2025.07.01 ~ 2025.07.31 (1개월)

기술 스킬

- 언어/프레임워크: Python, SQL
- 데이터 파이프라인: Airflow, DBT, Pandas, Spark
- Data Lake: AWS S3
- Data Warehouse: AWS Redshift
- ML: Implicit
- 시각화 대시보드: Preset

역할

- ETL 자동화: Airflow + dbt 적재 및 배치 처리 자동화
- 데이터 마트 구성: 상품 인기도 / 고객 프로파일 / 브랜드 KPI / 일별 KPI
- 마트 설계 및 구축
- Airflow Master-Worker 분산 아키텍처 구축
- ML 서빙: FastAPI / Streamlit으로 개인화 추천 제공




Data Flow

데이터 규모

일 평균 220만 건 배치처리

배치 스케줄

- 00:30 UTC — S3 → REDSHIFT 적재
- 01:00 UTC — DBT 마트 갱신
- 매일 자동 실행함, 전날 데이터 기준 T-1 처리



왜 이 기술을 선택했나?

01

Apache Airflow

dag 관리하기 용이하고 **실패 시 자동 재 시도**와 알림이 가능함

03

Apache Spark

Pandas로는 메모리 한계 문제가 있을 때 **분산처리를 수행함**

05

Implicit(ALS)

사용자의 행동에 따른 **암묵적 피드백**에 적합한 머신러닝 알고리즘.

02

dbt

데이터 변환 로직을 SQL로 모듈화 하여 **버전관리와 테스트**를 할 수 있음. **리니지**로 추적하기에도 용이

04


S3 + Redshift

s3는 **저비용**으로 원본 데이터 저장가능. Redshift는 컬럼형 MMP로 **대용량 집계**에 최적화 됨

트러블 슈팅

1) Worker 로그 접근 불가

문제 로그 URL에 IP가 비어있음



원인 1) hostname 미고정 → Airflow 가 빈 값을 기록
2) MASTER_IP = 퍼블릭 IP → VPC 내 보안 그룹 차단

해결 docker-compose-worker.yaml에 hostname: < 프라이빗 IP> 명시
MASTER_IP → 프라이빗 IP 로 변경

트러블 슈팅

2) CI/CD SCP 배포 시 권한 오류

문제 tar 압축 중 Permmision denied 발생 → 전송실패

```
22 drone-scp version: v1.6.14
23 tar all files into /tmp/yGmsQUJchD.tar.gz
24 remote server os type is unix
25 scp file to server.
26 create folder /home/ec2-user/realtime_ecommerce_final
27 untar file yGmsQUJchD.tar.gz
28 error: tar: ./dags/dbt_daily_mart_refresh.py: Cannot open: Permission denied
29 tar: ./dags/daily_raw_data_load.py: Cannot open: Permission denied
30 tar: ./dags/test_cicd.py: Cannot open: Permission denied
31 tar: ./dags/test_cicd_v2.py: Cannot open: Permission denied
```

원인 1) source: "." 으로 설정 시 .git 폴더까지 포함되어 압축 시도
2) Docker가 파일을 root 소유로 변경

해결 chown으로 파일 소유권 ec2-user로 복구
.git 제외한 코드만 압축

주요성과

01) 엔드투엔드 파이프라인 구축

→ S3 원본 데이터 수집부터 추천 서비스 제공까지 전 과정 자동화

데이터엔지니어링 역량

02) 분산 인프라 및 배포 자동화

→ Master-Worker EC2 분리 구성 + GitHub Actions Smart 배포로 운영 효율화

운영 효율화

03) 개인화 추천 시스템 구현

→ 사용자 행동(view · cart · purchase) 데이터를 학습한 ALS 모델로 유저별 개인화 상품 추천 제공

비즈니스 가치 창출

2) 대규모 의료 데이터 분석

주제 : 중환자의 생명유지능력향상을 위한 인공호흡기 발관판단 머신러닝에서의 글라스고우 혼수척도 기반 데이터구조화

데이터 : MIMIC-IV


? 문제정의

- 1. 중환자실에서 기관내삽관 환자들의 발관 (관 제거)타이밍을 정확히 예측하는 것이 어려움
- 2. MIMIC-IV 데이터셋에서 삽관/발관 데이터의 누락 및 짝이 맞지 않는 문제 발생

📄 연구방법


가설 : GCS의 Verbal Unable 구간은 환자의 삽관 상태를 반영하며, 이를 활용하면 MIMIC-IV에서 누락된 기계환기 이벤트 타임라인을 재구성할 수 있다

*글라스고우 혼수척도(GCS)는 환자의 의식 상태를 평가하기 위해 쓰이는 신경학적 평가 점수 척도이다



Unable 데이터를 활용한 삽/발관 시점 재구성
(X축: GCS 측정 시간 기록, Y축: GCS Unable 값의 점수, 점: Unable 기록, 점선: 삽/발관 기록, 회색구역: 삽관 상태)

삽관/발관 이벤트 타임라인 재구성 규칙



최종라벨링

모델링 및 결과

구분	변수
입력변수(X) - feature	gender (성별), los (입원 기간), duration_h (삽관 유지 시간), mean_sbp (평균 수축기 혈압), mean_hr (평균 심박수), mean_temp (평균 체온), mean_spo2 (평균 산소포화도), mean_ph (평균 혈액 산성도), mean_pao2 (평균 동맥혈 산소분압)
출력변수(Y)-label	outcome (Extubation Success(발관성공) / Failure(실패) / Death(사망))

<기존데이터와 최종데이터 모델 학습 결과 비교>

Add Unable	Acc.	F1
Before	0.88	0.84
After	0.88	0.85

→ Randomforest 학습데이터에 따른 모델의 정확도 및 F1-Score



결과

- GCS Verbal Unable 지표를 활용한 rule-based 전처리로 누락된 삽/발관 이벤트를 재구성하여 기존 대비 약 2배의 데이터 확보
- 데이터 증강 이후에도 모델 성능이 동등하게 유지되어 GCS Unable 기반 데이터 증강 접근법의 유효성을 확인

감 사 합 니 다