



중환자의 생명유지능력 향상을 위한 인공호흡기 발관 판단 머신러닝에서의 글라스고우 혼수척도 기반 데이터 구조화

Data Structuring Based on Glassgow Coma Scale in Machine Learning for Ventilator Extubation Determination to Improve the Life Support Capability of Critical Care Patients

김지연^{o1\$}, 은하영^{1\$}, 조인해^{1\$}, 최연준¹, 이수정², 홍승혁^{1*}

Jiyeon Kim^{o1\$}, Hayoung Eun^{1\$}, Inhae Cho^{1\$}, Yeonjun Choi¹, Sujung Lee² and Seunghyuk Hong^{1*}

{delay23; 21016051; whdlsgo2002; chlduswns99}@suwon.ac.kr, sujungle@outlook.com, shongdr@suwon.ac.kr

수원대학교 데이터과학부¹, 가톨릭대학교 의과대학 의료정보학교실²

\$: These authors contributed equally

1. 요약

MIMIC-IV 데이터셋의 글라스고우 혼수척도(Glasgow Coma Scale, GCS) Unable 데이터를 활용해 삽/발관 시점을 보완하는 방법을 제시하고, 인공지능 모델의 입력값을 위해 데이터를 정제하였다. 시간 순서에 맞게 중복된 삽/발관 이벤트를 처리한 후, 최종적으로 삽관과 발관 데이터를 확보했다. 이후 정제된 데이터를 사용해 발관 성공 여부를 예측하는 RandomForest, LightGBM, XGBoost 모델을 적용했으며, 그중 RandomForest 모델이 가장 좋은 성능을 보였다. 이 연구에서 수행한 데이터 오류 정정과 연구결과는 다른 연구의 참고 자료로 사용될 수 있으며, 이러한 작업을 바탕으로 개발된 AI 모델은 빠르고 정확한 의사 결정을 지원하는 시스템의 기반이 될 수 있다.

2. 서론

중환자실에선 기관 내 삽관을 하고 있는 환자들이 많다. 이 환자들이 호전되면 발관이 이루어져야 하는데 이 발관 타이밍을 더 정확히 하기 위해 MIMIC-IV 데이터를 이용해 분석하려 했다. 그러나 해당 데이터에서 삽/발관의 짝이 안 맞거나 누락이 발생한 것을 알게 되었다. 의료 연구에서 데이터의 누락은 연구 결과의 일반화를 저해하고 편향을 초래할 수 있다. 이를 해결하기 위해 MIMIC-IV 데이터셋에서 GCS의 Unable 데이터를 활용하여 삽/발관 데이터의 누락을 보완하고 완전성을 높임으로써 머신러닝 모델에 활용 가능한 데이터를 구축하는 데 중점을 두었다.

3. 데이터 전처리

• GCS의 Unable 데이터 정의

글라스고우 혼수척도(Glasgow Coma Scale, GCS)는 환자의 의식 상태를 평가하기 위해 쓰이는 신경학적 평가 점수 척도이다. 개안, 언어, 운동 반응으로 이루어져 있으며 1점부터 4, 5, 6점으로 구분한다. 3가지 항목 중 언어 반응은 삽관 상태에선 측정이 불가능하기 때문에 점수가 아닌 별도의 표기로 나타낸다.


분석을 진행한 GCS 데이터엔 unable 컬럼이 포함되어 있었는데, 이는 언어 반응의 점수가 0인 행과 대조되어 1로 나타났다. 즉, 언어 기능에 점수를 부여할 수 없는 경우에 0으로 표기한 것이다. 이를 새로운 컬럼 Unable을 추가하여 언어 반응이 측정되지 않았다면 1로, 언어 반응에 점수가 존재한다면 0으로 표기한 컬럼이다.

• 데이터 셋에서 발견한 오류 및 정정

- Verbal 점수와 Unable 값이 동시에 0으로 기록된 경우
→ Verbal 테스트를 수행할 수 없는 상태임을 의미한다고 해석하고, 해당 행의 Unable 값을 1로 수정
- Verbal 점수가 결측치(NA)로 기록된 경우
→ Verbal 테스트를 수행할 수 없는 상황임을 나타낸다고 판단하고, 해당 행의 Unable 값을 1로 수정

• Unable 데이터를 활용한 시간 생성 방법

Unable이 1로 지속되는 구간의 시작은 삽관이 시작된 시간으로 기록하였다. 반대로, Unable 값이 1에서 0으로 전환되는 시점은 환자가 더 이상 삽관이 필요하지 않아 발관이 완료된 시점으로 정의하였다. Unable 값의 변화를 기반으로 각각의 환자에 대해 삽/발관 시간을 설정하여 분석에 반영했다.



Unable 데이터를 활용한 삽/발관 시점 재구성
(X축: GCS 측정 시간 기록, Y축: GCS Unable 값의 점수, 점: Unable 기록, 점선: 삽/발관 기록, 회색구역: 삽관 상태)

4. 연구 방법

Unable 데이터를 활용해 생성된 삽/발관과 원본 삽/발관을 통합하기 위해 일렬로 정렬하는 과정에서 이벤트 중복이 발생할 수 있다. 삽/발관은 한 쌍(pair)을 이루는 성질이 있으므로 교차로 이벤트가 나타나야 한다. 따라서 삽관 또는 발관이 연속적으로 나타나는 경우를 중복으로 간주한다.

subject_id	hadm_id	stay_id	time	data_type	event_type	extubationcause
12124781	27861413	33431764	2187-11-24 18:30:00	real	intubation	NaN
12124781	27861413	33431764	2187-12-08 14:58:00	real	extubation	Planned Extubation
12124781	27861413	33431764	2187-12-12 06:25:00	real	extubation	Planned Extubation
12124781	27861413	33431764	2187-12-24 12:01:00	real	extubation	Planned Extubation

Extubation 중복


이를 해결하기 위해 삽/발관 삭제 및 생성 작업을 수행한다. 이때, 삭제는 Unable로 생성된 데이터에 한정된다.

subject_id	hadm_id	stay_id	time	data_type	event_type	extubationcause
14155070	28458535	30016432	2135-07-13 20:00:00	unable	extubation	NaN
14155070	28458535	30016432	2135-07-14 00:38:00	삭제	extubation	Planned Extubation
14155070	28458535	30016432	2135-07-14 08:00:00	unable	intubation	NaN
14155070	28458535	30016432	2135-07-14 11:27:00	real	intubation	NaN
14155070	28458535	30016432	2135-07-15 02:00:00	unable	extubation	NaN

원본 데이터는 삭제하지 않기 때문에, 원본 데이터에서 중복이 발생할 경우에는 삽/발관 데이터의 짝을 맞추기 위해 새로운 데이터를 생성한다.

subject_id	hadm_id	stay_id	time	data_type	event_type	extubationcause
18361380	29615907	32950965	2174-04-22 18:00:00	real	intubation	NaN
18361380	29615907	32950965	2174-04-22 18:06:00	real	intubation	NaN
18361380	29615907	32950965	2174-04-22 20:00:00	unable	intubation	NaN
18361380	29615907	32950965	2174-04-24 08:00:00	unable	extubation	NaN

5. 모델링




• 모델링을 위한 데이터 셋 전처리

생체 신호, GCS 점수, ABGA 등 주요 변수가 모두 누락된 행을 제거하였으며, 모든 결측값은 0으로 대체하였다.

예측 변수인 class 컬럼은 failure, nonfailure, death의 세 가지 범주로 구성되어 있다. 이전 연구를 참고하여 발관 후 48시간 이내에 재삽관된 경우를 failure로, 발관 후 24~48시간 이내에 사망한 경우를 death로 분류하였으며, 그 외의 경우는 모두 nonfailure로 분류하였다.

• 클래스 불균형 해결

failure 클래스가 nontailure, death 클래스에 비해 데이터 수가 많아 편향되어 학습하거나 클래스의 예측 정확도가 낮아질 수 있으므로 SMOTE(Synthetic Minority Over-sampling Technique)와 언더샘플링 기법을 적용하여 클래스 균형을 맞추었다



6. 모델링 및 결과

model	Acc.	F1	Acc. (SMOTE)	F1 (SMOTE)	Acc. (Under)	F1 (Under)
Random Forest	0.88	0.85	0.91	0.91	0.80	0.80
LightGBM	0.74	0.66	0.74	0.74	0.70	0.70
XGBoost	0.78	0.72	0.77	0.77	0.75	0.75

샘플링 기법에 따른 모델별 정확도 및 F1-Score

모든 모델이 SMOTE 적용 시 정확도 및 F1-Score가 가장 높게 나왔으며 이는 클래스 불균형을 잘 처리한 것으로 해석할 수 있다. 이중 RandomForest가 가장 좋은 성능을 보여주어 해당 모델을 이용하여 Unable 삽/발관 데이터를 추가하기 전후의 정확도와 F1-Score를 비교하고자 한다.

• 기존 데이터와 최종 데이터 모델 학습 결과 비교

학습 결과 기존 데이터 대비 최종 데이터로 학습한 모델의 정확도와 데이터로 학습한 모델의 정확도와 F1-score는 각각 0.03 낮아졌지만, 이는 모델의 분류 성능에 큰 영향을 미치지 않는 수준으로 해석된다.

기존 데이터 대비 최종 데이터는 삽/발관 데이터가 약 2배 증가했으며 이를 통해 모델의 일반화 능력을 높이고자 한 시도는 성과를 보였다.

Add Unable	Acc.	F1	Acc. (SMOTE)	F1 (SMOTE)
Before	0.88	0.84	0.94	0.94
After	0.88	0.85	0.91	0.91

모델: SMOTE 적용된 Randomforest
학습 데이터에 따른 모델의
정확도 및 F1-Score

7. 결론

삽/발관 데이터는 환자의 인공호흡기 제거 성공 여부를 예측하는 데 있어 핵심적인 변수이다. 본 연구에서는 부족한 원본 삽/발관 데이터의 보완하기 위해 GCS Unable 데이터를 활용하였으며, 이를 통해 기존 대비 약 2배의 삽/발관 데이터를 확보하였다. 이는 GCS 점수가 정기적으로 모니터링되는 지표이고, 시간 경과에 따른 환자 상태 변화를 지속적으로 파악할 수 있기에 가능하다. 이러한 특성은 원본 삽/발관 데이터의 누락을 보완하고, 인공지능 모델 학습에 필요한 더 많은 시계열 데이터를 확보하는 데 기여한다.

8. Acknowledgements

* 본 연구는 2023년도 중소벤처기업부의 기술개발사업 지원에 의한 연구임 [RS-2023-00222659]